Universidad de Valparaíso

Escuela de Ingeniería Informática

Software Asistido por LLM

MIRA Entrega 2

Informe de implementación del proyecto

Incremento F4 y F1

Grupo conformado por: Francisca Meyer, Lukas Scheel y Sebastián Rodríguez

Representante del cliente E2: Sebastián Rodríguez

Método: BMAD

Versión de referencia: v2.0

Fecha de entrega: 19 de octubre de 2026

Contenido

6.1 Resumen ejecutivo

6.2 Introducción y selección de funcionalidades

6.3 Aplicación del método

6.4 Implementación

6.5 Pruebas y verificación

6.6 Comparativa con la Entrega 1

6.7 Discusión

6.8 Conclusiones

Anexos y referencias

6.1 Resumen ejecutivo

Se construyó una aplicación web de MIRA que conecta F4, decisión por umbrales, con F1, bandeja de revisión asistida. Con datos ficticios, la aplicación permite evaluar un caso, explicar por qué se deriva a revisión, consultar evidencia y registrar una decisión, corrección o solicitud de antecedentes con motivo e historial.

El trabajo se desarrolló con BMAD a partir de la Entrega 1. Los tres cambios más relevantes fueron: fijar reglas verificables para aprobar o derivar casos, transformar la revisión humana en acciones justificadas que conservan el dato original y agregar persistencia con control de versiones para evitar pérdida de historial o dobles decisiones sobre el mismo caso.

Sebastián (cliente) aceptó la versión anterior de F4 y F1 en una sesión global sin observaciones. Las pruebas con dos personas externas mostraron que ambas tareas pueden completarse, aunque una participante necesitó ayuda.

La revisión del 17 de octubre mejora la orientación de las pantallas, la lectura de la bandeja y la recuperación ante errores. Conserva las reglas originales y se verificó en navegador y distintos tamaños de pantalla.

6.2 Introducción y selección de funcionalidades

MIRA es una plataforma de apoyo a decisiones empresariales a partir de evidencia multimodal. La Entrega 1 organizó requisitos, decisiones, hallazgos y backlog; la Entrega 2 convierte una selección de ese análisis en software ejecutable y trazable.

Elegimos F4 - Evaluación automática de casos y F1 - Revisión humana asistida. F4 utiliza puntajes y señales del motor simulado y aplica la política; los casos derivados se revisan en F1 sobre la misma evaluación. La conexión cumple la regla de selección. El riesgo principal es aprobar sin sustento o perder el fundamento de una intervención. La selección aborda H-15 y H-18 y conserva HU-03/04 y RQF-004/005/014 como origen.

Grupo conformado por: Francisca Meyer, Lukas Scheel y Sebastián Rodríguez. El representante del cliente rota de Lukas en E1 a Sebastián en E2. La baseline F4/F1 y las secciones 1 a 13 de la bitácora registran selección, aclaraciones y validación del brief, sin modificar retroactivamente los artefactos de E1.

Para facilitar la lectura, E1 y E2 designan las entregas 1 y 2; la baseline es la base de requisitos seleccionados de E1. Los identificadores FR y NFR corresponden a requisitos funcionales y no funcionales de E2; PF y PX identifican pruebas funcionales y extra-funcionales de E1.

El método es BMAD, con los roles Analyst, PM, UX, Architect, PO, SM, Dev y QA, y con configuración y artefactos conservados en _bmad/ y _bmad-output/. Los contratos SPEC complementan el trabajo de los roles con expectativas ejecutables. La configuración _bmad/config.toml identifica la implementación utilizada.

El stack efectivo es Python 3.13.16, Django 5.2.17, SQLite, Playwright, pytest y psutil, con dependencias fijadas en uv.lock. Django ofrece plantillas y pruebas integradas; SQLite permite ejecución local. La revisión mantiene HTML y CSS y añade JavaScript local para foco y asociaciones accesibles; no incorpora paquetes, servicios ni frameworks nuevos. El motor real queda fuera del alcance de E2.

6.3 Aplicación del método

Recorrido desde E1 hasta la implementación

La entrada del método fue la baseline específica F4/F1, extraída del análisis E1. El brief V2 fue validado antes del PRD; luego se generaron UX, arquitectura, validaciones, cuatro SPEC y 33 historias. El plan de cierre documentó las correcciones al starter y la revisión posterior comprobó contratos y comportamiento.

Fase	Entrada y artefacto producido	Ajuste documentado
Analyst	Análisis E1 y baseline hacia Product Brief V2.	Brief validado: F4/F1, parámetros del piloto y ausencia de rechazo automático.
PM	Brief y DEC-E2-01 a 07 hacia PRD y addendum.	Motivos por acción, Otro con comentario y calendario precisados.
UX Expert	PRD hacia DESIGN y EXPERIENCE.	Evidencia primero y flujos de error, decisión, corrección y conflicto.
Architect	PRD y UX hacia ARCHITECTURE SPINE.	SQLite, versiones, transacciones y mediciones; runtime efectivo 5.2.17.
PO	PRD y arquitectura hacia validaciones de consistencia.	Se comprobaron referencias y contratos; la divergencia tecnológica quedó registrada.
SM	Cuatro SPEC y épicas hacia 33 historias.	Capacidades vinculadas a FR/NFR y HU-03/04; dependencias verificadas.
Dev	Plan aprobado hacia código, fixtures y migraciones.	Persistencia sustituye memoria; decisiones y correcciones versionadas.
QA	Contratos, PF/PX y corpus hacia suites, mediciones y revisión.	Carrera con SQLite de archivo, regresiones de errores y sesiones humanas de cierre.

Traducción de decisiones y aclaraciones

Primer ejemplo. DEC-01 de E1 mantiene el umbral como candidato y prohíbe el rechazo automático. El brief conserva esa restricción; DEC-E2-01/02/04 concretan T=90 y mínimos de 70 para autenticidad y coherencia. SPEC-F4 y PF-04 verifican fronteras, señales ausentes y fraude con precedencia. Una entrada incompleta nunca se transforma en aprobación.

Segundo ejemplo. DEC-10/11 fijan plazos, evidencia antes del puntaje, motivo y conservación del original. El PRD los traduce a FR-9/11/12/15/16. F1 preserva el importe original y muestra la meta interna de tres días hábiles y el compromiso contractual de cinco, en America/Santiago y de lunes a viernes.

Q-01/02 resolvieron mínimos y umbral mediante decisiones del piloto. Q-03 aclaró que F4 utiliza el puntaje suministrado por el motor simulado y no define una fórmula nueva. Q-05 fijó categorías por acción y comentario obligatorio para Otro; Q-07 concretó calendario y alertas. La base de requisitos y la sección 9 de la bitácora registran las respuestas, sin atribuir al cliente intervenciones individuales no documentadas.

Corrección humana con antes y después

Un starter 356b4d5 marcaba discrepancia al aprobar o rechazar. El usuario corrigió esa interpretación y aprobó DEC-E2-08: decidir no implica desacuerdo, el operador lo declara con comentario y una corrección registra discrepancia. 74b8149 y 1cd0378 documentan intención y aprobación; a59ab9c incorpora el comportamiento y las pruebas. La decisión funcional correspondió al usuario y la generación del parche al agente.

La arquitectura y UX se revisaron mediante validaciones de consistencia y referencias; la fragmentación comprobó capacidades, historias y dependencias. El runtime inicialmente declarado como Django 5.2.18 se reconcilió con 5.2.17, autorizado en story 1.3 y efectivo en el entorno. Las secciones 14 a 20 de la bitácora y los registros QA preservan esos cambios.

Valor y costo del método

Los contratos y QA aportaron el mayor valor técnico observable: las pruebas de valores límite, reinicio y modificaciones concurrentes comprobaron propiedades que una demo visual no demostraba. El costo menos productivo fue mantener SPEC duplicados y reconciliar referencias tecnológicas. Esa evaluación se apoya en los artefactos corregidos; no hay horas, tokens o costos fiables para cuantificar ahorro frente a E1.

Nuevo ciclo de mejora de la interfaz

El 17 de octubre, UX Expert revisó contratos, plantillas, CSS y actas y registró diez hallazgos. El usuario aprobó la propuesta antes de implementar. Architect fijó la compatibilidad con Django y la conservación de reglas; SM derivó cinco historias; Dev modificó presentación y contexto de errores; QA comprobó recorridos y tamaños de pantalla [R13]. Antes, el nombre completo de F4 ocupaba un recuadro de 56 × 56 px y la tabla tenía ocho columnas con anchos definidos solo para seis. Después, el texto dispone de espacio flexible y se dimensionan las ocho columnas, con desplazamiento contenido cuando falta ancho. La revisión detectó además desbordamiento en tablet y pérdida de foco tras usar el enlace de salto; ambos se corrigieron y verificaron.

6.4 Implementación

La aplicación sigue un monolito modular. Las vistas reciben la interacción del navegador; los servicios coordinan reglas de dominio y persistencia. SQLite guarda evaluaciones e intervenciones y el reloj controlado de Santiago hace reproducibles los plazos. No hay llamadas al motor real ni servicios productivos.

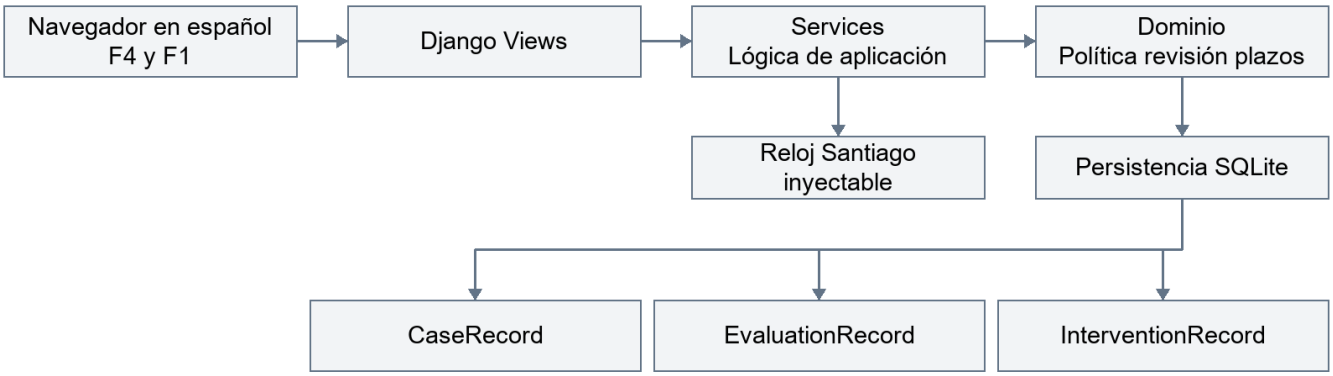


Figura 1 Arquitectura del incremento

Modelo efectivo. CaseRecord(case_id, version, payload, current_values); EvaluationRecord(case, case_version, inputs, policy, result) conserva evaluación original; InterventionRecord(case, version, kind, payload) conserva decisiones/correcciones, autor declarado, fecha, motivo y discrepancia. La restricción caso/versión es única. El control de concurrencia CAS (compare-and-swap) verifica la versión esperada, incrementa la versión y agrega un evento en una sola transacción. La API y los modelos de historial impiden modificar o eliminar registros existentes; la modificación directa mediante SQL queda fuera de las garantías de esta demostración local.

Estado funcional. F4 evalúa los casos de prueba y permite corregir entradas inválidas. F1 muestra archivos PDF y PNG con evidencia ficticia, registra decisiones y correcciones con motivos, detecta conflictos de versión y conserva el historial y los plazos. La validación extra-funcional AD-15 sigue pendiente; la identidad del operador es declarada y no dispone de autenticación para producción. Quedan fuera las nuevas evidencias, la reapertura completa, el panel agregado del supervisor, el motor real y F2/F3/F5…F9. Corregir el importe no recalcula la evaluación ni invalida una decisión anterior.

Interfaz revisada. Se conserva la identidad clara y verde, con nombres completos, acción «Evaluar caso», ocho columnas de bandeja, controles mejor alineados y separación de decisión, corrección e historial. Los estados humanos se diferencian por texto y color; los errores se vinculan a controles y reciben foco. Los campos introducidos se conservan al fallar un envío. Las capturas actuales se presentan en el anexo A [R13].

Procedencia del código. No se implementaron líneas de código directamente por el equipo; en cambio, el equipo realizó correcciones sobre la implementación mediante revisiones e instrucciones canalizadas a través del agente LLM.

Figuras 2 a 4 Interfaces actuales de F4, bandeja F1 y detalle del caso, en el anexo A

6.5 Pruebas y verificación

Pruebas funcionales y extremo a extremo

El cierre técnico anterior registra 33 pruebas Django y ocho pytest aprobadas. PF-04 cubre CC-F4-01 a 09: fronteras 59,99/60/90/90,01, fraude, señales menores de 70 o ausentes, automatización desactivada y error. NaN e infinitos se tratan como entradas inválidas. PF-05 prueba motivos compatibles, Otro con comentario, corrección de 120000 a 100000 y conflicto de versión. PF-14 verifica plazos y casos vencidos abiertos. Son resultados históricos y no se presentan como ejecución de toda la suite sobre la revisión local.

En la revisión local se aprobaron 33 pruebas Django y siete pruebas pytest seleccionadas [R13]. El recorrido integrado de Chromium verifica las nueve salidas F4, recuperación de error, PDF/PNG, corrección, solicitud y conflicto entre sesiones. La prueba nueva de UX recorre tres pantallas a 320, 360, 390, 768 y 1366 px sin desbordamiento global; comprueba navegación móvil, encabezados accesibles, evidencia antes del puntaje, casilla de discrepancia, Tab/Shift+Tab y foco en errores. Las pruebas usan una base aislada. El conteo de siete no reemplaza el histórico de ocho ni implica ejecución de toda la suite.

Rendimiento y aceptación de la desviación

Se midieron 100 casos con tres evidencias, cinco calentamientos y 30 muestras. Los recursos se observaron durante 30 revisiones, con 84 muestras y sin brechas de contadores [R3].

Indicador	Observado	Umbral	Resultado
Latencia p95	0,5228 s	≤ 2 s	Cumple en el entorno medido.
Memoria máxima	798,2 MiB	≤ 1 GiB	Cumple en el entorno medido.
CPU promedio	1,3237 núcleos	≤ 1 núcleo	Exceso de 32,4 %, aceptado por el cliente.

El cliente acepta el rendimiento actual sin observaciones, incluida la desviación de CPU [R6]. Se conserva el umbral original; no se atribuye el exceso a error de medición.

Usabilidad y aceptación funcional

Dos participantes externas completaron tareas F4 y F1 en la interfaz anterior, según el acta histórica [R4]. Sus tiempos y asistencias se conservan en la tabla.

Participante	Tiempo F4	Tiempo F1	Ayudas	Resultado
Fernanda Meyer, 21 años	30 s	3 min	Una por tarea	Ambas completadas con asistencia.
Ximena Belmar, 53 años	57 s	2 min 21 s	Ninguna	Ambas completadas de forma autónoma.

Fernanda fue observada por Francisca el 04/10/2026 a las 11:05 y necesitó identificar botones y comprender secciones. Ximena fue observada por Lukas el 03/10/2026 a las 21:09, sin dificultades. Las ayudas observadas motivaron instrucciones más claras y separación de acciones.

Sebastián probó F4/F1 el **04/10/2026 a las 13:00** y aceptó ambas por responder a lo solicitado, sin observaciones ni rechazos [R5]. El acta registra aceptación global por funcionalidad.

Funcionalidad	Alcance respaldado por el acta	Resultado	Limitación
F4	Responde a la evaluación por política del piloto y muestra resultado y explicación.	Aceptada.	No desglosa umbral, mínimos, fraude ni errores como criterios individuales.
F1	Responde a revisión humana y registro de intervención.	Aceptada.	No desglosa evidencia, motivo, corrección, conflicto ni plazos como criterios individuales.

No hubo rechazos en la sesión de aceptación registrada.

6.6 Comparativa con la Entrega 1

Se evalúa únicamente la baseline F4 y F1, sin afirmar cobertura de todo MIRA.

Evolución de requisitos

Requisito E1	Clasificación propuesta	Cambio/resultado y evidencia
RQF-004 Must	Precisado, conservado	T90, mínimos 70 y precedencia; FR1…6, SPEC-F4, PF04.
RQF-005 Must	Precisado, conservado	Motivos por acción, CAS, importe original/corregido; FR7…14, SPEC-F1, PF05.
RQF-014 Must	Precisado, conservado	3/5 días Santiago L-V; FR15/16, PF14; vencido abierto.
RQF-003 Must apoyo	Adaptado al motor simulado	Señales/hallazgos ficticios visibles; FR6/9, PDFs/PNG; no se implementa inferencia.
RQF-008 Must apoyo	Recortado a F4/F1	Procedencia/evaluación/intervención durable; FR5/17, reinicio; F6 completo queda fuera del alcance.
RQNF-009 Must	Precisado para corpus	PX09 nueve salidas; piloto sin ampliación ni tasa objetivo.
RQNF-001 Must	Precisado, validación parcial	AD15 y script p95; hardware acordado no acreditado.
RQNF-005 Should	Validado parcialmente con personas	Orden visual y dos sesiones externas; orientación mejorable y condiciones formales PX-05 sin acreditar íntegramente.
RQNF-008 Should	Medido y aceptado con excepción	RSS cumple; CPU excede umbral. Cliente acepta resultado [R6]; hardware requerido sin acreditar.

Supuestos y decisiones

Supuesto/decisión	Origen verificable	Evolución y quién consta
T candidato, nunca rechazo automático	DEC01; baseline §4	DEC-E2-02 limita 90 al piloto; bitácora§9; pruebas respetan.
Mínimos sin fijar (H15)	baseline §5 y PF04 m 70	DEC-E2-01/04 precisa 70 y dos señales; aclaración documentada, no inferencia nueva.
F4 calcula score	descripción/enunciado frente a E2 motor simulado	DEC-E2-03 aclara consumo; baseline §11; no inventa fórmula.
Tres frente a cinco días	DEC10/H16	DEC-E2-07 separa meta y compromiso; reloj controlado.
Evidencia primero y original íntegro	DEC11/H18	FR9/12 y pruebas; sesiones externas identifican dificultad de orientación [R4].
Discrepancia automática al decidir	starter 356b4d5 frente a plan	Usuario aprueba DEC-E2-08, 74b8149/1cd0378; agente implementa declaración/corrección.
Django 5.2.18 declarado	arquitectura/SPEC inicial	Usuario aprobó 5.2.17 en story1.3; reconciliación efectiva, historial conservado.
Aceptación funcional y rendimiento	Cierre técnico anterior con sesiones pendientes	Sebastián acepta F4/F1 [R5]; cliente acepta rendimiento con desviación CPU [R6]. Equipo registra; agente instrumenta medición.

En la Entrega 1, el trabajo se centró en analizar, planificar y diseñar los aspectos de MIRA mediante métodos de prompting. Este enfoque permitió explorar ideas y definir requisitos con una menor exigencia de conocimientos técnicos. Sin embargo, la organización dependía de cómo se formulaban las preguntas y se revisaban las respuestas, lo que dificultaba mantener la precisión, la consistencia entre documentos y la trazabilidad de las decisiones. Las ambigüedades podían trasladarse a etapas posteriores y afectar la calidad de la implementación final.

En la Entrega 2, el uso de BMAD permitió organizar el desarrollo en fases y roles, conectando los requisitos de E1 con especificaciones, historias, código y pruebas. Esta estructura facilitó identificar contradicciones, corregir interpretaciones y verificar el comportamiento de las funcionalidades F4 y F1. La mejora en precisión y trazabilidad se

observa en los artefactos y las pruebas del repositorio, aunque requirió mayor conocimiento técnico y revisión humana: el método no garantizó por sí solo una implementación correcta.

Respecto del tiempo, el prompting de E1 podía generar avances rápidos al inicio, pero su menor estructura favorecía revisiones y retrabajo cuando aparecían inconsistencias. BMAD ayudó a ordenar esas revisiones y controlar mejor los cambios, aunque también añadió trabajo documental. Por ello, consideramos que E2 ofreció un proceso más controlado y una base más confiable para implementar MIRA.

Indicadores calculados

I1 Cobertura de trazabilidad de Must seleccionados. En la línea base histórica, los Must con SPEC, historia, código y prueba divididos por los seleccionados son 7/7 × 100 = 100 % [R2]. Mide existencia de cadena, no cumplimiento de NFR-3. La matriz desarrolla 22 FR/NFR derivados.

I2 Exactitud de la política en el corpus F4. Salidas esperadas correctas divididas por casos F4 ejecutados: **9/9 × 100 = 100 %**. Las expectativas provienen de policy-cases.md, verificadas por PF-04 y E2E. El corpus ficticio pequeño no demuestra exactitud del motor ni fraude real.

I3 Cumplimiento extra-funcional observado. Umbrales satisfechos divididos por umbrales medidos: **2/3 × 100 = 66,7 %** [R3]. p95 y RSS cumplen, CPU no. La aceptación del cliente conserva ese numerador. La acreditación AD-15 se informa aparte y sigue pendiente.

Respuestas sobre requisitos y decisiones

A1 Cambios. La tabla clasifica los nueve requisitos de la baseline; los cambios relevantes precisan barreras, motivos, concurrencia y plazos. No se reescriben retroactivamente IDs E1.

A2 Must sin cadena. Ninguno de los siete seleccionados carece de cadena contractual/técnica; NFR3 tiene prueba y evidencia, pero no aceptación en hardware. Must de F2/F3/F5…F9 están fuera por selección explícita F4/F1, no por olvido; no se afirma inventario total E1.

A3 Agregado sin fuente. Marcar discrepancia por toda aprobación/rechazo era una regla del starter, de origen no acreditado, corregida por DEC-E2-08 con criterio de desacuerdo explícito. No se aceptó como nueva regla de negocio; no se atribuye su autoría histórica al agente.

A4 RNF no automatizable. La comprensión en PX-05 no puede certificarse por navegador: las dos sesiones registradas aportan tiempos y dificultades, pero no acreditan todas las condiciones formales del participante. Es una limitación de evidencia automática, no del requisito. AD-15 sí es medible; aquí limita el entorno y PX-08 falla CPU, aunque el cliente acepta la desviación.

B1 Supuestos invalidados. La persistencia en memoria del starter no cumplía reconstrucción/reinicio y la discrepancia automática no correspondía al desacuerdo declarado; auditoría/plan registran esos problemas, el usuario aprueba cierre y el agente cambia implementación. No se atribuye su detección a Sebastián.

B2 Decisiones respetadas y contradichas. Se respetan DEC01/10/11 (política/plazos/evidencia); starter contradijo conservación y semántica de desacuerdo, y contratos divergían del runtime autorizado. La comparación de 356b4d5/4337a3a con a59ab9c y bitácora§14 documenta corrección. DEC08 sobre nueva evidencia se mantiene fuera según SPEC-F1, sin simular reapertura.

B3 Ambigüedad resuelta por el agente. La prioridad y permanencia operativa de antecedentes abiertos se proyectan desde estados/contratos; creación de borrador corregido usa nuevo identificador para preservar fixture. Son opciones técnicas del agente; Sebastián aceptó el resultado global sin observaciones [R5]. Esa aceptación respalda el comportamiento presentado, pero no prueba una aprobación individual retrospectiva de cada opción técnica.

Respuestas sobre consistencia y calidad

C1 Hallazgos. H15 se precisa con 70 para piloto, no calibración productiva; H18 dispone de sesiones externas y dificultad de orientación identificada; faltan condiciones formales de PX-05. Nuevas brechas de implementación: la persistencia en memoria perdía el historial, las modificaciones concurrentes podían entrar en conflicto y las decisiones generaban discrepancias implícitas; estas brechas se corrigieron. Queda abierta acreditación AD15; CPU permanece como excepción aceptada por el cliente, sin cambiar el umbral.

C2 Contradicciones de arquitectura. La divergencia entre Django 5.2.18 y 5.2.17 se reconcilia. No se construye el motor real aunque el menú del enunciado menciona cálculo, pues su sección 4.3 y DEC-E2-03 establecen puntajes y señales simulados. F6 completo queda fuera del alcance.

D1 Modelo. Los casos incorporan versión/valores actuales; evaluación conserva inputs/política/result; intervención agrega versión, kind y payload. Son necesarios para reconstrucción y CAS, sin expediente F6.

D2 Precisión de aceptación. PF04 tiene fronteras útiles; mínimos, catálogo y calendario requieren DEC-E2-01/05/07. PF05 necesita convertir “motivo” a códigos de categoría y versión esperada; PX08/AD15 necesitan volumen/herramienta/umbrales concretos. Los documentos SPEC complementarios contienen la reformulación ejecutable, sin elegir expectativas desde resultados del código.

El cierre técnico fue revisado con cuatro lentes BMAD; los hallazgos, refutaciones y parches están en registro de revisión. No hubo hallazgos diferidos; las sesiones humanas se incorporan en los registros [R4/R5], mientras el entorno acordado sigue sin acreditar.

6.7 Discusión

BMAD aportó una estructura útil para conservar la relación entre necesidades y comportamiento. La baseline evitó reiniciar el análisis desde la descripción general y los contratos convirtieron decisiones en comprobaciones. La persistencia y el control de concurrencia muestran su mayor beneficio: un formulario podía parecer terminado y aun así perder historial o aceptar dos cambios sobre el mismo estado. Esas propiedades necesitaron pruebas independientes del recorrido visual.

El método también generó mantenimiento sin comportamiento adicional. Las copias de SPEC y las referencias tecnológicas divergentes exigieron reconciliación. La existencia de documentos no demuestra coherencia: deben compararse con runtime, datos y pruebas. La revisión del usuario fue necesaria para impedir que el agente tratara una decisión humana como desacuerdo implícito.

La validación con personas aporta otra clase de evidencia. Fernanda completó el recorrido con ayuda para localizar botones y entender secciones; Ximena lo resolvió sin asistencia. La diferencia señala una oportunidad de orientación, pero la muestra no permite afirmar que la interfaz es universalmente intuitiva ni establecer diferencias por edad. La aceptación global de Sebastián respalda la adecuación general a lo solicitado en la sesión registrada y conserva las dificultades de uso como oportunidades de mejora.

El ciclo de mejora muestra cómo una observación de uso puede convertirse en cambios verificables: las ayudas para ubicar botones y entender secciones motivaron instrucciones, grupos y errores más claros. Las pruebas técnicas comprueban reflujo, foco y conservación de datos, pero no demuestran menor esfuerzo humano. Mantener esa diferencia evita declarar resuelto un problema de comprensión solo porque pasa una prueba automatizada.

El rendimiento exige separar satisfacción del cliente y acreditación técnica. El cliente acepta la desviación de CPU porque considera aceptable el resultado actual, mientras el requisito mantiene su umbral. Esta decisión no transforma el entorno medido en 2 vCPU y 4 GiB. Conservar ambos resultados permite justificar aceptación sin ocultar límites.

Frente al prompting directo de E1, E2 añade código ejecutable, pruebas y control del historial; mejora la posibilidad de verificar decisiones y detectar pérdida entre especificación e implementación. No contamos con métricas comparables de horas o tokens para afirmar menor esfuerzo. SDD podría haber centrado el proceso en la especificación; en este proyecto, el control observable provino de revisar contratos y someterlos a pruebas además de organizar el trabajo por roles.

6.8 Conclusiones

El incremento demuestra que el equipo ahora puede llevar una baseline de requisitos a una aplicación con dos funcionalidades conectadas, preservar decisiones de origen y localizar su evidencia en contratos, historias, código y pruebas. El aprendizaje principal fue que una especificación asistida por agentes solo es confiable cuando se contrasta con decisiones, runtime, datos y pruebas ejecutables; en este caso, esa revisión permitió descubrir problemas de persistencia, concurrencia y semántica de discrepancia que una demo visual no habría mostrado.

La versión anterior de F4 y F1 fue aceptada en la sesión registrada. La revisión local del 17 de octubre mejora la presentación sin modificar política, modelos, plazos ni control de concurrencia. Se verificaron recorridos y adaptación de pantalla; quedan pendientes repetir usabilidad con personas, revisar accesibilidad con tecnologías de apoyo y renovar trazabilidad cuando se autorice versionar. La aceptación del rendimiento y sus límites técnicos se mantienen históricos.

El uso de BMAD fue beneficioso porque nos permitió transformar el análisis de MIRA en un proceso de desarrollo organizado y verificable. La división por roles y fases facilitó conectar requisitos, decisiones, especificaciones, código y pruebas, además de detectar inconsistencias antes de considerarlas resueltas. Aprendimos que el valor del método depende también de revisar sus resultados: los artefactos generados por el agente requieren supervisión y validación humana.

Al aprender a utilizar BMAD, ampliamos nuestra capacidad para conducir un proyecto asistido por IA. Pasamos de formular instrucciones y revisar respuestas a gestionar un desarrollo completo, evaluar propuestas técnicas, corregir interpretaciones y comprobar funcionalidades mediante pruebas. Este aprendizaje nos entrega una base más sólida para abordar proyectos de mayor complejidad, con mejor trazabilidad y mayor control sobre la implementación final.

Anexos y referencias

Anexo A Capturas de la interfaz revisada

Capturas técnicas del 17 de octubre de 2026, tomadas con datos ficticios y base de pruebas aislada. Las vistas corresponden al estado local con mejoras locales respecto de la etiqueta v2.0. El visor PDF puede mostrar un enlace alternativo en el navegador de pruebas.

Figura 2 F4 Evaluación automática de casos

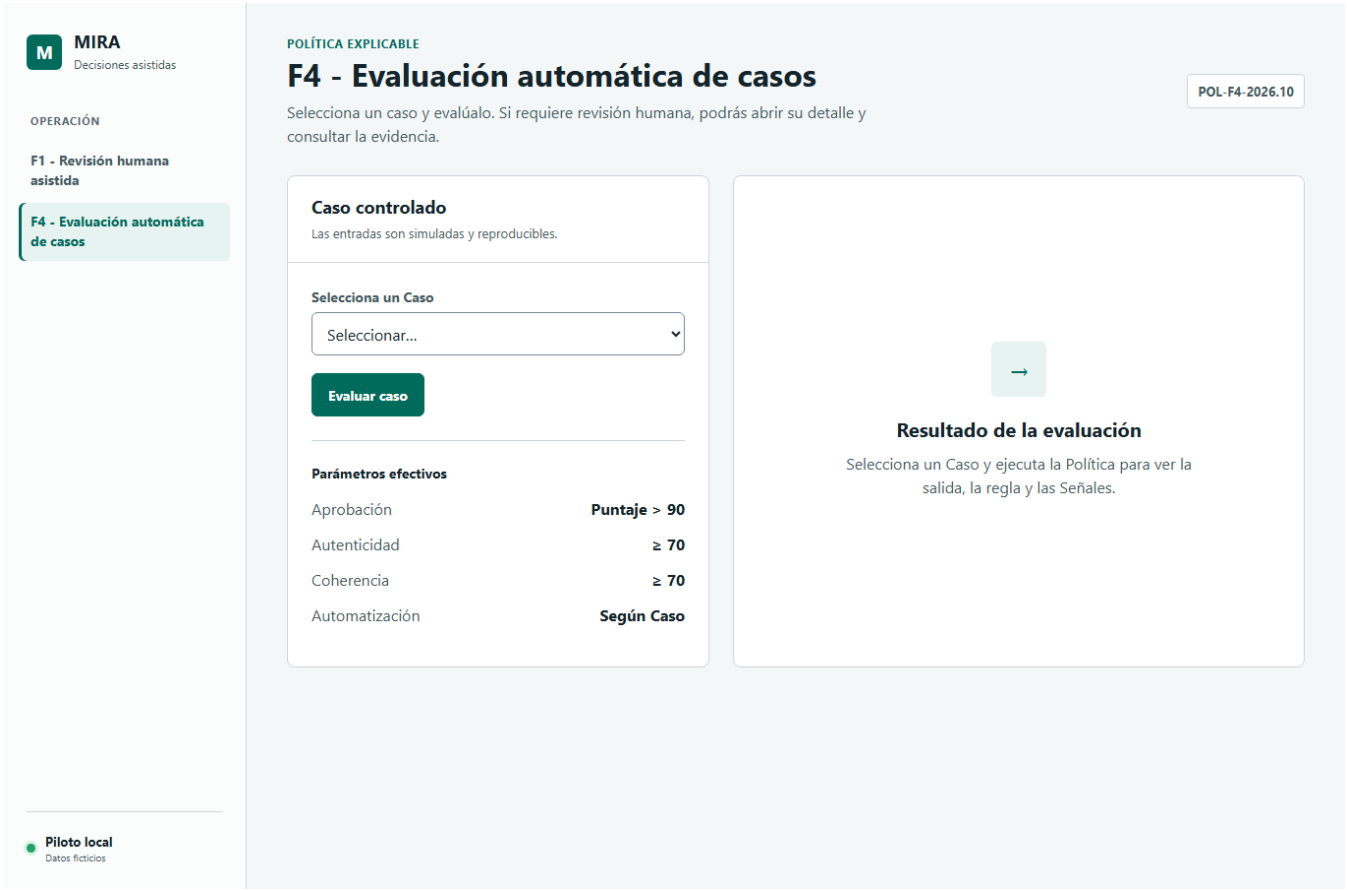


Figura 3 F1 Revisión humana asistida

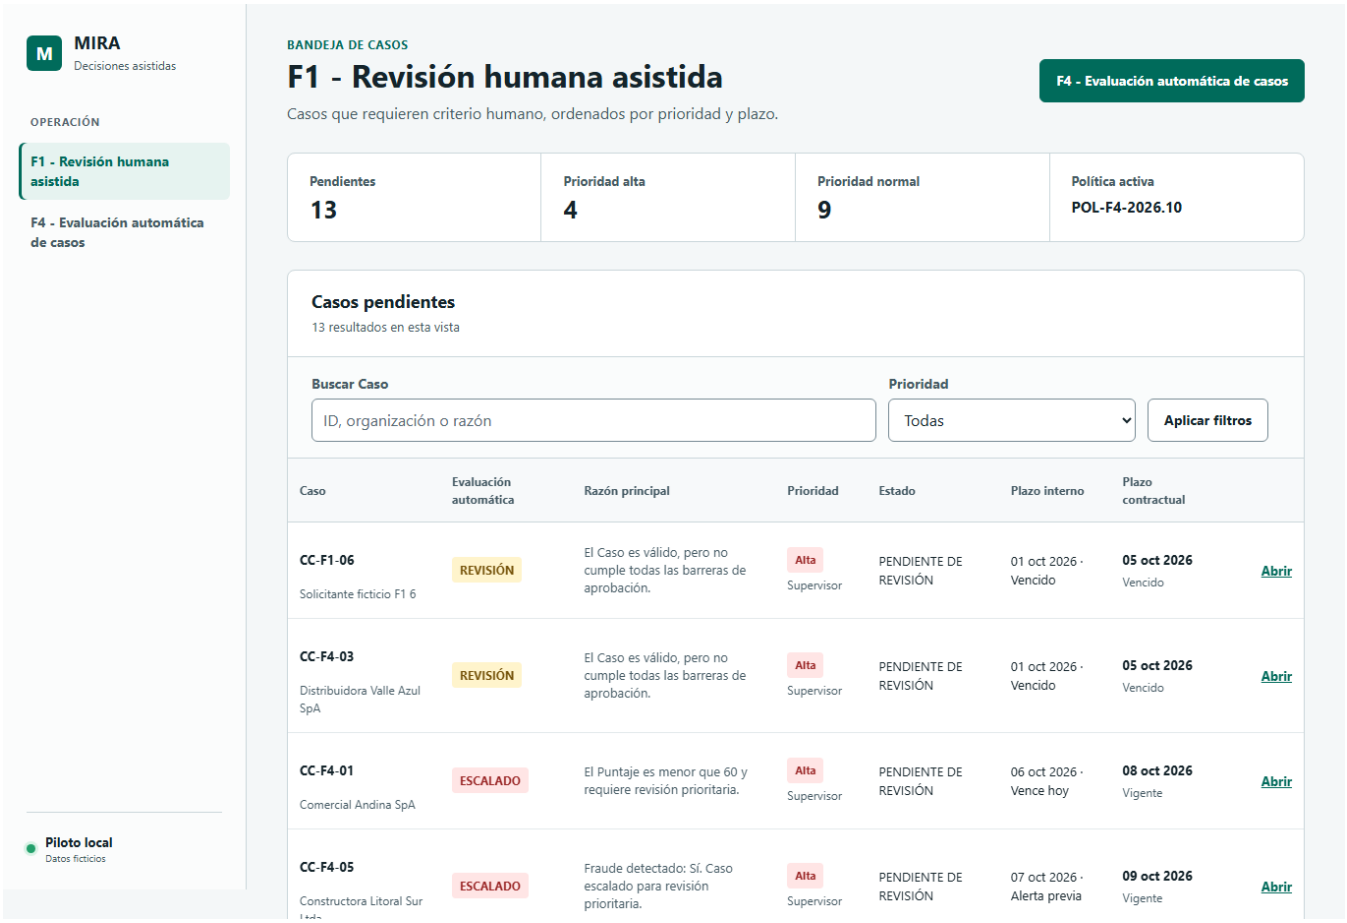
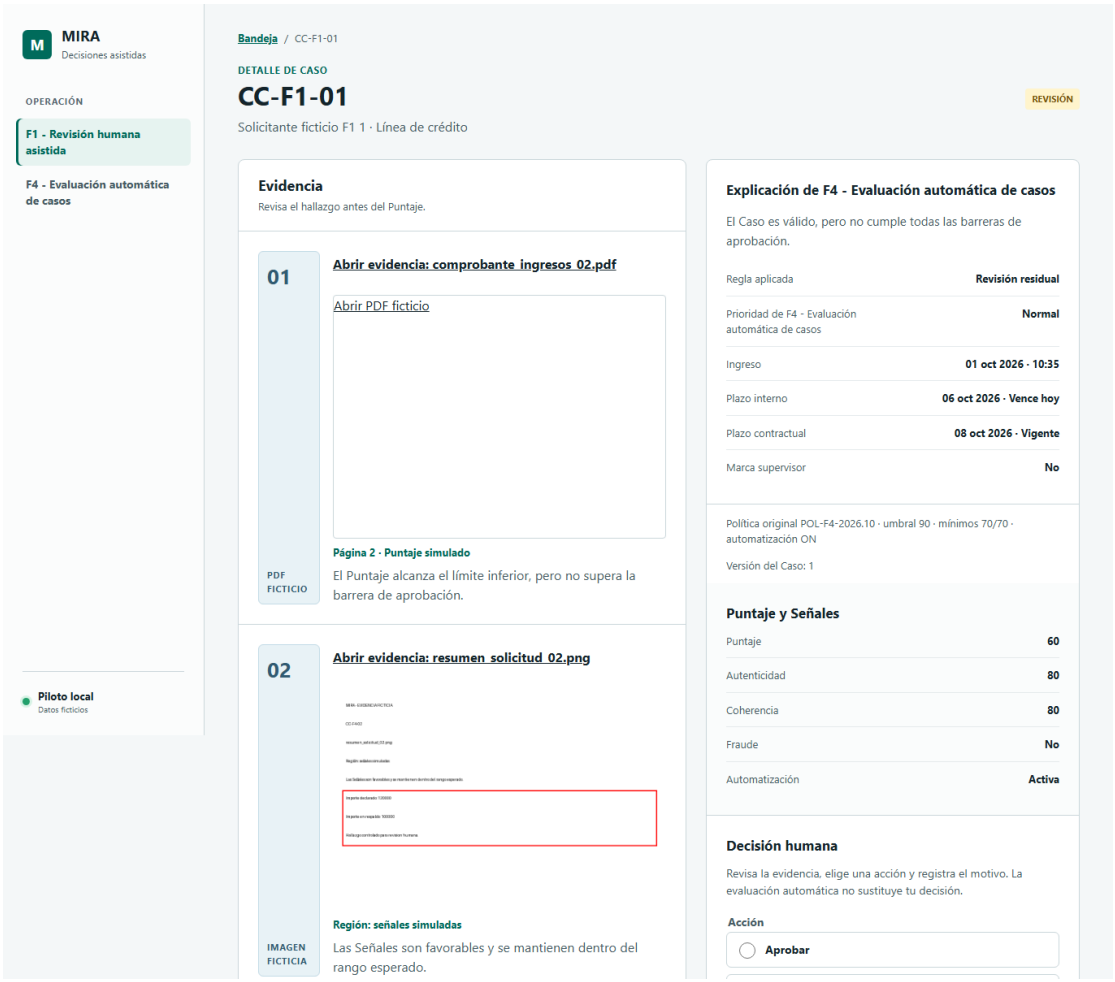


Figura 4 Detalle de revisión humana y evidencia



Anexo B Evidencia y referencias del repositorio

R1. LLM - MIRA_E2_Baseline_F4_F1.md: decisiones, requisitos y hallazgos de origen.

R2. docs/trazabilidad-must.md y docs/qa/traceability.json: matriz histórica de Must y requisitos derivados.

R3. docs/qa/measurements.json: configuración y muestras históricas de rendimiento.

R4. docs/qa/usabilidad-px05.md: actas originales; no constituyen prueba del rediseño.

R5. docs/qa/aceptacion-sebastian.md: aceptación original de F4/F1 del 4 de octubre de 2026.

R6. docs/qa/aceptacion-rendimiento.md: aceptación de la desviación de CPU.

R7. README.md y docs/qa/instalacion-readme.md: instalación y reproducción.

R8. LLM - MIRA_Entrega2_bitacora_decisiones.md: secuencia de decisiones y actualizaciones.

R9. _bmad/config.toml y _bmad-output/: artefactos del método.

R10. docs/qa/review-bmad.md, tests/ y src/mira/web/tests.py: revisión y pruebas.

R11. Contexto-fase1-bmad/LLM - Entrega_2_MIRA_SDD_BMAD.pdf: enunciado E2.

R12. prompts_completos.md y docs/qa/commit-author-map.json: asistencia y procedencia.

R13. docs/qa/frontend-2026-10-17/QA.md y contrast.json; tests/test_frontend_ux.py; _bmad-output/planning-artifacts/ux-designs/ux-mira-mejora-frontend-2026-10-17/; _bmad-output/implementation-artifacts/frontend-mira-2026-10-17/: propuesta aprobada, contratos, arquitectura, cinco historias y evidencia de revisión local.